

Analisis Sentimen dan Aspek Opini Publik terhadap Brand Produk Teknologi Asing dan Lokal (Studi Kasus : Xiaomi dan Advan)

Muhammad Luthfi Aziz Sunarya¹, Danish Rahadian Mirza Effendi², Athallah Azhar Aulia Hadi³, Naufal Fakhri Ilyas⁴, Dr. Afrida Helen, S.T., M.Kom.⁵

¹Fakultas Matematika dan Ilmu Pengetahuan Alam - Universitas Padjadjaran, Kab. Sumedang, 45363 Indonesia, danish23003@mail.unpad.ac.id

²Fakultas Matematika dan Ilmu Pengetahuan Alam - Universitas Padjadjaran, Kab. Sumedang, 45363 Indonesia, athallah 23004@mail.unpad.ac.id

³Fakultas Matematika dan Ilmu Pengetahuan Alam - Universitas Padjadjaran, Kab. Sumedang, 45363 Indonesia, muhammad23427@mail.unpad.ac.id

⁴Fakultas Matematika dan Ilmu Pengetahuan Alam - Universitas Padjadjaran, Kab. Sumedang, 45363 Indonesia, naufal22007@mail.unpad.ac.id

⁵Fakultas Matematika dan Ilmu Pengetahuan Alam - Universitas Padjadjaran, Kab. Sumedang, 45363 Indonesia, helen@mail.unpad.ac.id

Corresponding Author: Muhammad Luthfi Aziz Sunarya

INTISARI — Dominasi produk teknologi impor di pasar Indonesia, khususnya merek Xiaomi, menunjukkan tingginya preferensi konsumen terhadap produk asing yang berpotensi menekan daya saing industri nasional. Di sisi lain, merek lokal seperti Advan menghadapi tantangan signifikan dalam hal persepsi kualitas dan loyalitas pengguna. Penelitian ini bertujuan untuk menganalisis sentimen publik serta mengidentifikasi aspek krusial yang membedakan kepuasan pengguna antara merek asing dan lokal. Pengumpulan data ulasan dilakukan melalui teknik web scraping menggunakan pustaka Selenium dan BeautifulSoup. Metode penelitian yang digunakan adalah Supervised Learning. Untuk efisiensi pelabelan data, penelitian ini menerapkan pendekatan Semi-Supervised Annotation (SSA), di mana pelabelan awal sentimen (positif, negatif, netral) dilakukan oleh model AI Generatif dengan atribut *Confidence Level*, yang kemudian divalidasi melalui evaluasi manual oleh kami sebelum digunakan untuk melatih model. Tahapan pra-pemrosesan data meliputi cleansing, case folding, tokenization, normalisasi kata, *stemming* dan stopword removal. Penelitian ini juga menggunakan teknik Negation Merging (penggabungan negasi, contoh: "tidak bagus" menjadi "tidakbagus") guna mempertahankan konteks semantik kalimat. Ekstraksi fitur teks dilakukan menggunakan metode TF-IDF, dan klasifikasi sentimen dibangun menggunakan model dengan akurasi terbaik dari percobaan beberapa model seperti Logistic Regression, SVM, Naive Bayes dan Random Forest. Aspek-aspek yang menjadi sorotan pengguna dianalisis lebih lanjut menggunakan visualisasi WordCloud serta LDA untuk menganalisis kekurangan dari produk lokal. Hasil penelitian ini diharapkan dapat memberikan wawasan mengenai peta persaingan persepsi antara produk teknologi asing dan lokal di Indonesia.

KATA KUNCI — Analisis Sentimen, Xiaomi, Advan, *Semi-Supervised Annotation (SSA)*, *Negation Merging*, *LDA*.

I. PENDAHULUAN

A. LATAR BELAKANG

Indonesia saat ini tengah mengalami fase transformasi digital yang masif, ditandai dengan peningkatan penetrasi teknologi informasi dan komunikasi di kalangan masyarakat. Berdasarkan data Badan Pusat Statistik (BPS) dari hasil Survei Sosial Ekonomi Nasional (Susenas), pada tahun 2024 tercatat 72,78 persen penduduk Indonesia telah mengakses internet, meningkat dari 69,21 persen pada tahun 2023. Tingginya aksesibilitas ini didukung oleh kepemilikan perangkat seluler yang juga terus meningkat, di mana pada tahun 2024 tercatat 68,65 persen penduduk Indonesia telah memiliki telepon seluler[12]. Fenomena ini menjadi indikator kuat kesiapan Indonesia dalam menghadapi era ekonomi digital, sekaligus mencerminkan stabilnya permintaan terhadap layanan digital di mana sektor informasi dan komunikasi mencatatkan pertumbuhan tertinggi keenam pada tahun 2024 sebesar 7,57 persen[12].

Pertumbuhan sektor digital ini sejalan dengan optimisme pemerintah terhadap ekonomi makro. Menurut Menteri Keuangan Sri Mulyani Indrawati, pemerintah menargetkan pertumbuhan ekonomi Indonesia mencapai 5,4% pada tahun 2026 sebagai pijakan awal menuju skenario jangka menengah sebesar 8% (Kemenkeu, 2025)[15]. Dalam konteks ini, keberadaan produk dan merek lokal memiliki peran strategis. Merek lokal tidak hanya bertindak sebagai pendorong

roda ekonomi, tetapi juga berfungsi sebagai ekspresi identitas budaya dan inovasi domestik[15]. Oleh karena itu, penguatan merek lokal menjadi krusial untuk menjaga ketahanan ekonomi nasional.

Namun, ironi terjadi ketika melihat neraca perdagangan sektor Teknologi Informasi dan Komunikasi (TIK). Data statistik menunjukkan bahwa nilai ekspor barang TIK Indonesia mengalami penurunan sebesar 2,22 persen pada tahun 2024 menjadi AS\$7.371 juta. Sebaliknya, impor barang TIK justru meningkat 4,59 persen menjadi AS\$13.552 juta, yang didominasi oleh komponen elektrik dan perangkat komputer[12]. Ketimpangan ini mengindikasikan bahwa meskipun adopsi teknologi masyarakat tinggi, pemenuhannya masih sangat bergantung pada produk asing. Hal ini diperkuat oleh pernyataan Menteri Koordinator Bidang Perekonomian, Airlangga Hartarto, pada Januari 2025 yang mengungkapkan bahwa sebanyak 10 juta orang terkaya di Indonesia lebih memilih bertransaksi untuk produk luar negeri karena ketidaktersediaan atau kurangnya daya tarik produk di dalam negeri[13].

Preferensi masyarakat terhadap merek asing dibandingkan merek lokal menjadi tantangan serius. Berdasarkan penelitian Wenas, konsumen Indonesia rela membayar lebih mahal untuk produk global karena tiga faktor utama: kualitas dan bahan baku, model yang dianggap lebih trendy, serta nilai sosial atau prestise[13]. Selain itu, fenomena

globalisasi dan digitalisasi turut memperparah kondisi ini. Kemudahan akses informasi dan pengaruh media sosial menciptakan lingkungan di mana produk luar negeri menjadi lebih mudah dijangkau dan dianggap sebagai standar gaya hidup modern [13]. Kondisi ini menempatkan merek lokal seperti Advan dalam posisi yang sulit saat harus bersaing dengan raksasa teknologi asing seperti Xiaomi, yang telah memiliki persepsi merek yang kuat di benak konsumen Indonesia.

Untuk meningkatkan daya saing merek lokal, Affandi et al. (2025) menekankan bahwa pemahaman mendalam mengenai konsumen sangatlah penting [14]. Perlu adanya analisis yang komprehensif untuk membedah apa yang sebenarnya dipikirkan dan dirasakan publik terhadap produk lokal vis-à-vis produk asing. Analisis sentimen berbasis ulasan pengguna (review) menjadi pendekatan yang efektif untuk menangkap opini publik secara jujur dan real-time. Namun, analisis sentimen pada teks berbahasa Indonesia memiliki tantangan tersendiri, terutama terkait konteks negasi yang sering kali mengubah makna kalimat (misalnya, "tidak bagus" yang bermakna negatif sering kali salah diklasifikasikan jika kata "tidak" dipisah dari kata sifatnya). Oleh karena itu, penelitian ini bertujuan untuk menganalisis sentimen dan aspek opini publik dengan membandingkan merek asing (Xiaomi) dan merek lokal (Advan). Penelitian ini menerapkan teknik web scraping menggunakan Selenium dan BeautifulSoup untuk mendapatkan data ulasan yang lebih dinamis. Pendekatan Supervised Learning diterapkan dengan inovasi pada tahap pelabelan menggunakan Semi-Supervised Annotation (SSA) yang dibantu AI dan divalidasi secara manual. Selain itu, tahap pra-pemrosesan menambahkan teknik Negation Merging untuk menjaga keutuhan konteks semantik. Melalui metode ini, diharapkan dapat teridentifikasi aspek-aspek spesifik yang perlu diperbaiki oleh merek lokal agar mampu merebut kembali kepercayaan pasar domestik di tengah dominasi produk asing.

B. TUJUAN

Tujuan dari penelitian ini adalah sebagai berikut:

1. Menganalisis perbandingan sentimen publik terhadap *brand* teknologi asing (Xiaomi) dan lokal (Advan) guna memahami persepsi konsumen di tengah tingginya penetrasi internet dan penggunaan perangkat seluler di Indonesia.
2. Mengidentifikasi aspek-aspek dominan (seperti kualitas, inovasi, dan harga) yang menjadi faktor penentu preferensi konsumen, untuk menjawab tantangan mengapa produk asing lebih diminati dibandingkan produk lokal.
3. Memberikan kontribusi ilmiah berupa pemetaan persepsi masyarakat terhadap produk teknologi lokal dan asing, yang dapat menjadi rujukan akademis untuk studi perilaku konsumen di era transformasi digital.
4. Memberikan wawasan (*insight*) strategis bagi pengembangan industri teknologi lokal agar mampu meningkatkan kualitas dan daya saingnya terhadap produk impor, dalam rangka mendukung target pertumbuhan ekonomi dan kemandirian industri nasional.
1. Memberikan Wawasan Strategis bagi Industri Lokal Menyediakan data empiris bagi pelaku industri teknologi dalam negeri (khususnya Advan) untuk mengevaluasi posisi mereka terhadap kompetitor asing, serta mengidentifikasi celah inovasi yang diperlukan untuk meningkatkan kualitas dan merebut kembali pangsa pasar.
2. Pemetaan Preferensi Konsumen Menghasilkan pemahaman mendalam mengenai faktor-faktor utama (seperti harga, spesifikasi, dan citra merek) yang memicu sentimen positif atau negatif masyarakat, sehingga dapat menjelaskan alasan di balik dominasi produk impor dibandingkan produk lokal.
3. Kontribusi Referensi Ilmiah Menambah khazanah literatur dan menjadi rujukan akademis mengenai penerapan analisis sentimen untuk membandingkan persepsi publik terhadap merek produk teknologi, serta menjadi acuan bagi studi selanjutnya dalam bidang penggalian data opini (*opinion mining*) dan perilaku konsumen digital.
4. Dukungan terhadap Kemandirian Ekonomi Mendukung agenda pemerintah dalam memperkuat ekonomi nasional dengan memberikan rekomendasi berbasis data yang dapat digunakan untuk mendorong daya saing produk lokal dan mengurangi ketergantungan terhadap impor barang TIK (Teknologi Informasi dan Komunikasi).

D. BATASAN MASALAH


1. Sumber Data Data ulasan pengguna (*user reviews*) diambil secara eksklusif dari platform *e-commerce* Tokopedia. Pengambilan data dibatasi hanya pada ulasan yang terdapat di Official Store (Toko Resmi) dari masing-masing merek (Xiaomi Official Store dan Advan Official Store) untuk menjamin validitas ulasan terhadap produk yang otentik.
2. Teknik Pengumpulan Data Proses pengambilan data ulasan dilakukan menggunakan teknik *web scraping* dengan memanfaatkan pustaka Selenium dan BeautifulSoup.
3. Objek Penelitian Objek penelitian difokuskan pada perbandingan dua merek produk teknologi, yaitu Xiaomi (sebagai representasi merek asing) dan Advan (sebagai representasi merek lokal).
4. Bahasa Ulasan yang dianalisis hanya ulasan yang ditulis dalam Bahasa Indonesia untuk memastikan relevansi konteks lokal.

II. KAJIAN TERKAIT

A. ANALISIS SENTIMEN

Analisis sentimen merupakan proses menganalisis penilaian, sikap, emosi, opini, evaluasi seseorang terhadap suatu produk. Berdasarkan definisi oleh (Samsir et al., 2021) analisis sentimen adalah upaya mengelompokkan teks di dalam sebuah dokumen atau kalimat yang memiliki polaritas tertentu sehingga dapat diklasifikasikan menjadi netral, negatif atau positif [20]. Menurut (Anees, Shaikh, Shaikh, & Shaikh, 2020) ada dua pendekatan yang bisa dilakukan untuk menganalisis sentimen yaitu *machine learning* dan *lexicon based* [21]. lebih jelasnya seperti gambar di bawah ini

C. MANFAAT



Gambar 1. Taksonomi Metode Analisis Sentimen

B. LOGISTIC REGRESSION

Sebuah paper menunjukkan bahwa penulis melakukan Logistic Regression untuk anotasi sentimen, penulis juga melakukan *Semi-supervised annotation* (SSA) untuk pelabelan[10]. model klasifikasi sentimen ini dibandingkan akurasi dengan model baseline yang diberi label manual oleh para pakar. Lalu model klasifikasi yang digunakan adalah *Logistic Regression* dan *Naive Bayes*. Dataset yang digunakan adalah dataset IMDB sebanyak 50.000 record yang berisi review film dan model dievaluasi menggunakan confusion matrix.

Penulis membagi dua data menjadi data training dan data testing dengan perbandingan 8:2 dan dataset dibagi menjadi Dataset1, Dataset2, Dataset3, Dataset4 dengan jumlah data berlabel dibagi menjadi 625, 1250, 2500 dan 5000 dan sisanya sebagai unlabeled dataset. Penulis melakukan *preprocessing* seperti tokenisasi, ubah ke *lowercase*, menghapus *stopword* dan *special character* kemudian di *stemming*. dari hasil pengujian didapatkan hasil bahwa model regresi menggunakan *logistic regression* dibanding *naive bayes*.

C. STOPWORDS REMOVAL & STEMMING

Sebuah paper menunjukkan bahwa penulis melakukan *sentiment analysis* dengan tujuan untuk mengetahui pengaruh *stopwords removal* dan juga *stemming* dalam meningkatkan akurasi modelnya[11]. Metode yang digunakan adalah *machine learning* dengan *supervised learning*. Dataset diambil dari indonesia twitter emotion dataset yang mengandung label dan juga tweet. dari hasil eksperimen yang dilakukan didapatkan hasil sebagai berikut

TABEL I
Perbandingan Performa Model Berdasarkan Teknik Preprocessing Teks

Model	F1-Score	Waktu Proses
Tanpa Stemming dan Stopwords	62.7%	385.3 ms
Dengan Stopwords	63.3%	265.5 ms
Dengan Stemming	65.0%	208.9 ms
Dengan Stemming dan Stopwords	64.8%	141.7 ms

Dari tabel ini didapatkan kesimpulan bahwa dengan menggunakan *stopwords removal* dan juga *stemming* dapat membantu model dalam menganalisis sentimen dari sebuah teks. Selain meningkatkan akurasi model penggunaan *Stemming* dan *Stopwords removal* pada dataset juga membuat

processing lebih cepat sehingga training dengan data yang besar bisa lebih efektif secara penggunaan waktu.

D. NORMALIZATION

Menurut Firdausi, Indriati, dan Ridok (2017), normalisasi teks merupakan tahapan krusial dalam pra-pemrosesan (pre-processing) yang berfungsi mengubah data teks tidak terstruktur menjadi lebih terstruktur, khususnya untuk mengatasi kendala variasi bahasa di media sosial[16]. Dalam analisis sentimen terhadap ulasan pengguna di platform seperti Instagram, sering ditemukan penggunaan tata bahasa tidak standar, singkatan, dan kesalahan penulisan (typo) yang dapat menyulitkan model klasifikasi dalam memproses teks. Oleh karena itu, normalisasi diperlukan untuk menyeragamkan kata-kata slang atau tidak baku menjadi bentuk formalnya agar memudahkan pengolahan data oleh algoritma.

Penelitian tersebut membuktikan bahwa penerapan normalisasi kata slang efektif meningkatkan kinerja model klasifikasi. Tanpa normalisasi, model Naïve Bayes menghasilkan akurasi sebesar 0,872, sedangkan dengan penerapan normalisasi, akurasi meningkat menjadi 0,884. Peningkatan ini terjadi karena normalisasi memperbaiki kesalahan penulisan (seperti "smoga" menjadi "semoga"), yang memungkinkan proses stemming berjalan lancar dan memastikan perhitungan probabilitas kata (likelihood) terhadap kelas sentimen menjadi lebih akurat. Dengan demikian, normalisasi terbukti menjadi langkah positif untuk mendapatkan makna yang lebih akurat dari teks informal.

E. TF-IDF

TF-IDF adalah sebuah teknik yang digunakan sebagai upaya mempertimbangkan apakah sebuah kata dalam dokumen atau kalimat memiliki makna yang penting[22]. Secara matematis rumus TF-IDF adalah sebagai berikut,

$$tf-idf(t,d) = tf(td) \times idf(t)$$

Dengan rumus $tf(t,d)$, adalah sebagai berikut,

$$tf(t,d) = \frac{f_{t',d}}{\sum_{t' \in d} f_{t',d}}$$

dan rumus $idf(t)$ adalah sebagai berikut,

$$idf(t) = \log \frac{1+n}{1+df(t)} + 1$$

Sebuah paper menunjukkan bahwa penulis mencoba membandingkan metode pembobotan kata dengan TF-IDF dan Word2Vec dalam menganalisis sentimen *Cyber Bullying*[9]. penulis melakukan 3 skenario yaitu menggunakan pembobotan kata dengan TF-IDF, Word2Vec CBOW, Word2Vec Skip-gram. dataset diuji dengan model yang sama yaitu *Support Vector Machine* (SVM) sehingga perbandingan bisa lebih objektif kepada komparasi antara TF-IDF dan Word2Vec dalam pembobotan kata. Berikut adalah hasil dari uji coba yang dilakukan.

TABEL II
Perbandingan Representasi Teks pada Model SVM Kernel Linear untuk Deteksi Bullying

Skenario	Precision (non-bullying)	Recall (non-bullying)	F1-Score (non-bullying)	Precision (bullying)	Recall (bullying)	F1-Score (bullying)	Akurasi
TF-IDF, SVM kernel linear	83%	83%	83%	83%	83%	83%	83%
CBOW, SVM kernel linear	79%	75%	77%	76%	80%	78%	77%
Skip-gram, SVM kernel linear	80%	76%	78%	77%	80%	78%	78%

Penulis memberikan kesimpulan bahwa metode TF-IDF dengan SVM kernel linear memberikan hasil yang lebih baik dalam menganalisis sentimen dari sebuah dokumen.

F. LDA

Latent Dirichlet Allocation (LDA) merupakan salah satu algoritma pemodelan topik yang paling mapan dan banyak digunakan dalam bidang penambangan teks dan pemrosesan bahasa alami. Metode ini pertama kali diusulkan oleh Blei pada tahun 2002 sebagai model pembelajaran mesin tak terawasi yang bertujuan untuk menemukan struktur topik tersembunyi dalam sekumpulan dokumen besar. LDA didefinisikan sebagai model probabilistik generatif yang mengasumsikan bahwa setiap dokumen dalam korpus merupakan campuran dari berbagai topik, dan setiap topik itu sendiri merupakan distribusi probabilitas dari kata-kata [17], [18]. Pendekatan ini memungkinkan algoritma untuk merekayasa balik proses pembuatan dokumen guna mengungkap tema abstrak yang mendasari koleksi teks tersebut.

Mekanisme kerja LDA secara tradisional bergantung pada representasi fitur Bag of Words (BoW), di mana dokumen dianggap sebagai vektor frekuensi kata tanpa memperhatikan urutan kemunculannya. Dalam banyak implementasi, representasi ini sering diperkaya dengan transformasi Term Frequency-Inverse Document Frequency (TF-IDF) untuk memberikan bobot pada kata-kata yang penting namun jarang muncul di seluruh korpus [19]. Proses generatif LDA melibatkan tiga lapisan utama, yaitu lapisan kata, lapisan topik, dan lapisan dokumen, yang bekerja secara iteratif untuk memperbarui distribusi topik pada dokumen dan distribusi kata pada topik berdasarkan pola kemunculan bersama atau co-occurrence [17], [19]. Kinerja model ini sangat dipengaruhi oleh pengaturan hiperparameter, khususnya Alpha yang mengontrol kepadatan topik dalam dokumen, dan Beta atau Eta yang mengontrol kepadatan kata dalam topik [18], [19].

Keunggulan utama LDA terletak pada kemampuannya untuk menghasilkan kluster topik yang tegas dan terpisah dengan jelas. Berdasarkan studi komparatif pada data umpan balik mahasiswa, LDA terbukti efektif dalam mendefinisikan kluster yang berbeda (distinct clusters). Kualitas kluster ini sering diukur menggunakan Silhouette Score, yang menghitung

seberapa mirip sebuah objek dengan klasternya sendiri dibandingkan dengan kluster lain melalui persamaan:

$$S = \frac{b-a}{\max(a,b)}$$

di mana a adalah jarak rata-rata intra-kluster dan b adalah jarak rata-rata terdekat antar-kluster [19]. Selain itu, LDA dinilai mampu mengekstrak topik secara akurat pada dataset berskala besar dan memberikan hasil yang mudah diinterpretasikan secara statistik melalui distribusi kata-kata kunci yang dominan [17]. Popularitas metode ini bertahan karena fleksibilitas dan efektivitasnya dalam berbagai aplikasi penambangan teks konvensional [18].

Meskipun demikian, literatur mencatat beberapa keterbatasan signifikan LDA, terutama ketika diterapkan pada teks pendek atau yang membutuhkan pemahaman semantik mendalam. Kinerja LDA cenderung mengalami degradasi pada data teks pendek, seperti judul berita atau cuitan media sosial, karena kurangnya informasi kemunculan kata bersama yang menjadi landasan algoritma ini [18]. Selain itu, karena ketergantungannya pada pendekatan berbasis frekuensi istilah, LDA memiliki keterbatasan dalam menangkap nuansa makna kontekstual dan hubungan semantik antar kata jika dibandingkan dengan pendekatan berbasis *embedding* modern seperti BERTopic [19].

Evaluasi kinerja LDA umumnya dilakukan menggunakan metrik koherensi topik (Coherence Score) untuk menentukan jumlah topik yang optimal dan memastikan makna logis. Salah satu metrik yang umum digunakan adalah C_v , yang mengukur konsistensi semantik berdasarkan sliding window dan kesamaan vektor kata:

$$C_v(T) = \frac{2}{|T|(|T|-1)} \sum_{i=1}^{|T|} \sum_{j \neq i}^{i+T-1} \text{sim}(\text{Word}_i, \text{Word}_j)$$

di mana T adalah Himpunan kata-kata teratas dalam topik. dan $\text{sim}(\text{Word}_i, \text{Word}_j)$ adalah ukuran kesamaan (similarity) antara dua kata.

III. SOLUSI USULAN

Inti dari solusi yang kami ajukan adalah penerapan kerangka kerja analisis sentimen yang pragmatis dan terukur. Kami memilih beberapa model antara lain Naive Bayes, Logistic Regression, Random Forest, dan SVM yang didasarkan pada performa akurasi yang unggul dalam eksperimen awal serta rekam jejaknya yang solid dalam berbagai studi klasifikasi teks. Model ini menawarkan keseimbangan optimal antara kekuatan prediksi dan interpretasi hasil.

Lebih dari itu, untuk menjawab tujuan penelitian, kerangka ini diperkaya dengan metode Analisis Sentimen Berbasis Aspek (ABSA) dengan LDA. Langkah ini krusial untuk membongkar sentimen umum menjadi evaluasi yang lebih granular terhadap hal yang lebih spesifik seperti performa dan layanan pelanggan. Dengan demikian, solusi ini dirancang untuk menghasilkan wawasan strategis yang dapat ditindaklanjuti (*actionable insights*), yang pada akhirnya dapat menjadi landasan bagi para pemangku kepentingan dalam upaya mendukung kemandirian ekonomi digital Indonesia.

A. DATASET

Fondasi utama dari penelitian ini terletak pada dataset yang mampu merepresentasikan pengalaman nyata dan otentik

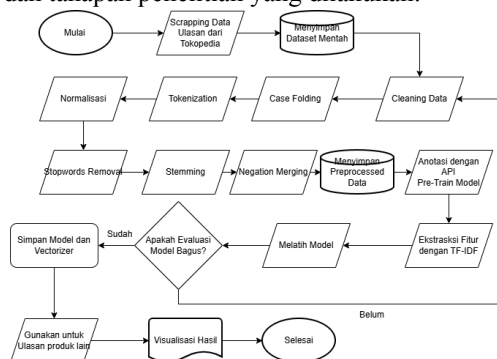
konsumen terhadap produk teknologi. Oleh karena itu, penelitian ini menetapkan platform e-commerce Tokopedia sebagai sumber data primer, dengan batasan pengambilan data secara eksklusif pada ulasan yang terdapat di Official Store (Toko Resmi) dari masing-masing merek. Pemilihan Official Store bertujuan untuk meminimalisir bias yang disebabkan oleh faktor eksternal (seperti pelayanan reseller pihak ketiga yang buruk atau produk palsu), sehingga ulasan yang didapatkan murni mencerminkan kualitas produk dan layanan resmi dari brand tersebut.

Fokus analisis ditujukan pada dua entitas merek yang menjadi studi kasus, yaitu Xiaomi (merek representasikan merek asing) dan Advan (merek representasikan merek lokal). Proses pengumpulan data dilakukan menggunakan teknik web scraping dengan memanfaatkan pustaka Selenium dan BeautifulSoup untuk mengekstraksi ulasan berbahasa Indonesia secara terstruktur. Data ulasan ini mencakup teks opini, penilaian (rating), dan waktu ulasan yang dianggap esensial untuk melatih model klasifikasi sentimen. Seluruh data yang diekstraksi bersifat publik..

B. METODE PENELITIAN

Alur penelitian diawali dengan tahap pengumpulan data ulasan dari Tokopedia melalui teknik scraping yang kemudian disimpan sebagai dataset mentah untuk diproses lebih lanjut. Data tersebut selanjutnya melewati serangkaian tahapan pra-pemrosesan yang sistematis, mencakup pembersihan data (cleaning), penyeragaman huruf (case folding), pemecahan kalimat (tokenization), normalisasi kata, penghapusan kata umum (stopword removal), hingga pengakaran kata (stemming), *negation merging* untuk menjaga konteks agar menghasilkan data bersih yang tersimpan dan siap dianotasi.

Tahap selanjutnya berfokus pada pengembangan model, dimulai dengan pelabelan data menggunakan API model ChatGPT 4 dan dievaluasi secara manual untuk confidence ≤ 0.8 setelah dievaluasi selanjutnya dilakukan ekstraksi fitur dengan metode TF-IDF sebagai masukan untuk pelatihan model. Kinerja model yang dihasilkan kemudian dievaluasi dengan menggunakan Akurasi, Precision, Recall, F1 Score, apabila hasilnya belum memuaskan maka proses akan dikembalikan ke tahap *preprocessing* untuk perbaikan, namun jika evaluasi menunjukkan hasil yang baik, model beserta vectorizer akan disimpan untuk diterapkan pada analisis ulasan produk lain dan diakhiri dengan visualisasi hasil penelitian. Berikut adalah diagram alur (*flowchart*) mengenai metode dan tahapan penelitian yang dilakukan:



Gambar 2. Flowchart tahapan dan metode penelitian untuk analisis sentimen

Penelitian dilanjutkan dengan analisis mendalam terhadap ulasan yang terklasifikasi sebagai sentimen negatif guna mengidentifikasi aspek keluhan spesifik dari produk Advan. Pada tahapan ini, metode ekstraksi fitur dialihkan menggunakan pendekatan Bag of Words (CountVectorizer) yang, berdasarkan studi komparasi awal, terbukti lebih efektif dalam menghasilkan koherensi topik dibandingkan TF-IDF untuk dataset ini. Algoritma Latent Dirichlet Allocation (LDA) kemudian diterapkan untuk mengungkap struktur topik tersembunyi (latent topics) dari korpus ulasan negatif. Guna mendapatkan model yang paling optimal, dilakukan proses Hyperparameter Tuning menggunakan metode Grid Search dengan memvariasikan jumlah topik ($k=3$ hingga $k=6$) serta parameter prior Dirichlet α (doc_topic_prior) dan η (topic_word_prior) pada rentang nilai 0.1, 0.5, dan 0.9.

Evaluasi kualitas model LDA didasarkan pada metrik Coherence Score (C_v) sebagai indikator utama untuk mengukur tingkat keterkaitan semantik antar kata dalam satu topik, serta Silhouette Score sebagai metrik pendukung untuk melihat separasi antar kluster. Konfigurasi model dengan nilai koherensi tertinggi dipilih sebagai model final untuk menjamin hasil yang mudah diinterpretasikan. Tahap akhir dari analisis ini melibatkan pelabelan aspek secara manual (human annotation) terhadap kumpulan kata kunci dominan yang terbentuk, serta perhitungan persentase distribusi topik dominan (dominant topic distribution) untuk mengkuantifikasi proporsi keluhan pada setiap aspek masalah, sehingga prioritas perbaikan produk dapat dipetakan secara akurat.

C. PENGAMBILAN DATA

Proses akuisisi data dilakukan secara terprogram untuk meminimalisir bias manual serta menjamin efisiensi pengumpulan informasi. Penelitian ini menerapkan metode web scraping kustom yang dikembangkan menggunakan bahasa pemrograman Python. Pendekatan ini mengintegrasikan pustaka Selenium WebDriver untuk keperluan otomatisasi peramban dan BeautifulSoup untuk penguraian struktur HTML. Pemilihan metode ini didasarkan pada karakteristik antarmuka platform Tokopedia yang bersifat dinamis dan berbasis JavaScript, sehingga memerlukan simulasi interaksi pengguna untuk memuat konten ulasan secara utuh.

Alur kerja pengumpulan data dimulai dengan inisiasi driver peramban yang dikonfigurasi dengan opsi khusus untuk mencegah deteksi aktivitas otomatisasi dan memastikan akses halaman berjalan lancar. Setelah mengakses tautan produk yang dituju, algoritma diprogram untuk menunggu hingga seluruh elemen halaman termuat, kemudian melakukan navigasi otomatis ke tab Ulasan guna menampilkan daftar komentar pengguna.

Proses ekstraksi data dilakukan melalui mekanisme iteratif atau perulangan. Pada setiap halaman ulasan, pustaka Beautiful Soup digunakan untuk membedah struktur Document Object Model (DOM) dan mengidentifikasi elemen yang memuat informasi relevan. Variabel rating diperoleh dengan cara menghitung jumlah elemen ikon bintang yang aktif pada setiap blok ulasan, sedangkan teks ulasan diambil dari elemen atribut yang memuat opini pengguna. Untuk menjangkau riwayat ulasan yang lebih lama, skrip dilengkapi dengan logika penanganan paginasi yang secara otomatis mendeteksi dan menekan tombol halaman berikutnya hingga batas jumlah data

yang ditentukan tercapai. Hasil akhir dari proses ini adalah dataset terstruktur dalam format Comma Separated Values (CSV) yang memuat variabel nama produk, rating, tanggal, dan teks ulasan sebagai masukan utama untuk tahap analisis selanjutnya dengan di bawah ini adalah contoh datasetnya.

TABEL III
Contoh data hasil *web scraping*

Produk	Rating	Tanggal	Ulasan
[Exclusive Vanda Rainy] ADVAN Smartwatch S1 AI Voice Assistant IPS Display 2.01" Touchscreen Waterproof IP68 Bluetooth Call Health Monitoring Jam Tangan Pintar Smartwatch Murah	5	Hari ini	Sangat puas, Trima kasih 🙏🙏
[Exclusive Vanda Rainy] ADVAN Smartwatch S1 AI Voice Assistant IPS Display 2.01" Touchscreen Waterproof IP68 Bluetooth Call Health Monitoring Jam Tangan Pintar Smartwatch Murah	5	Hari ini	Bagus banget jamnya
[Exclusive Vanda Rainy] ADVAN Smartwatch S1 AI Voice Assistant IPS Display 2.01" Touchscreen Waterproof IP68 Bluetooth Call Health Monitoring Jam Tangan Pintar Smartwatch Murah	5	Hari ini	cakep

D. PRA-PEMROSESAN DATA

Menghadapi karakteristik data ulasan yang sarat akan bahasa informal, singkatan (“yg”, “bgt”), dan salah ketik, tahap

pra-pemrosesan menjadi langkah krusial untuk standarisasi data. Tanpa pembersihan yang cermat, akurasi model akan sangat terdegradasi. Oleh karena itu, kami menerapkan pipeline pra-pemrosesan yang terdiri dari beberapa langkah kunci:

- 1) *Cleansing*: Eliminasi noise seperti URL, angka, dan karakter non-alfabetik. Berikut merupakan contoh data hasil *cleansing*:

TABEL IV
Contoh data hasil *cleansing*

ulasan	hasil_cleaning
keren emang bagus worthit dikelas harga nya. bagus advan mulai laptopnya semoga makin ditingkatkan kualitasnya	keren emang bagus worthit dikelas harga nya bagus advan mulai laptopnya semoga makin ditingkatkan kualitasnya
Performa: Oke bgt bisa dipakai utk kebutuhan olga	Performa Oke bgt bisa dipakai utk kebutuhan olga
Barang sampai dengan selamat dan pengiriman cepat... Terimakasih advan	Barang sampai dengan selamat dan pengiriman cepat Terimakasih advan
Performa: Jamnya keren, sampai ditempat dgn selamat	Performa Jamnya keren sampai ditempat dgn selamat
Keren ni...sukses terus advan	Keren ni sukses terus advan

- 2) *Case Folding*: Standardisasi teks dengan mengubah semua huruf menjadi huruf kecil. Berikut merupakan contoh data hasil *case folding*:

TABEL V
Contoh data hasil *case folding*

hasil_cleaning	casefolding
keren emang bagus worthit dikelas harga nya bagus advan mulai laptopnya semoga makin ditingkatkan kualitasnya	keren emang bagus worthit dikelas harga nya bagus advan mulai laptopnya semoga makin ditingkatkan kualitasnya

Performa Oke bgt bisa dipakai utk kebutuhan olga	performa oke bgt bisa dipakai utk kebutuhan olga
Barang sampai dengan selamat dan pengiriman cepat Terimakasih advan	barang sampai dengan selamat dan pengiriman cepat terimakasih advan
Performa Jamnya keren sampai ditempat dgn selamat	performa jamnya keren sampai ditempat dgn selamat
Keren ni sukses terus advan	keren ni sukses terus advan

3) *Tokenize*: Tokenisasi adalah proses membagi teks input, yang pada komputer hanyalah kumpulan karakter yang panjang, menjadi sub unit yang berbeda. Berubahnya karakter panjang menjadi suatu sub unit yang lebih kecil. Berikut merupakan contoh data hasil *tokenize*:

TABEL VI
Contoh data hasil *tokenize*

casefolding	tokenisasi
keren emang bagus worthit dikelas harga nya bagus advan mulai laptopnya semoga makin ditingkatkan kualitasnya	['keren', 'emang', 'bagus', 'worthit', 'dikelas', 'harga', 'nya', 'bagus', 'advan', 'mulai', 'laptopnya', 'semoga', 'makin', 'ditingkatkan', 'kualitasnya']
performa oke bgt bisa dipakai utk kebutuhan olga	['performa', 'oke', 'bgt', 'bisa', 'dipakai', 'utk', 'kebutuhan', 'olga']
barang sampai dengan selamat dan pengiriman cepat terimakasih advan	['barang', 'sampai', 'dengan', 'selamat', 'dan', 'pengiriman', 'cepat', 'terimakasih', 'advan']

performa jamnya keren sampai ditempat dgn selamat	['performa', 'jamnya', 'keren', 'sampai', 'ditempat', 'dgn', 'selamat']
keren ni sukses terus advan	['keren', 'ni', 'sukses', 'terus', 'advan']

4) *Normalization*: Normalisasi adalah proses penyeragaman teks yang bertujuan untuk mengubah bentuk kata yang tidak standar menjadi bentuk bakunya agar lebih mudah diproses oleh model. Dalam konteks ulasan di media sosial, kalimat sering kali mengandung variasi tata bahasa yang tidak baku, singkatan, kata gaul (slang), atau kesalahan pengetikan (typo) yang dapat menyulitkan pemrosesan teks. Oleh karena itu, normalisasi dilakukan dengan mengubah kata-kata informal tersebut menjadi padanan kata formalnya. Penerapan normalisasi terbukti efektif untuk mengatasi variasi bentuk kata dan membantu model menangkap makna yang lebih akurat dari sebuah komentar. Berikut merupakan contoh data hasil *normalization*:

TABEL VII
Contoh data hasil Normalization

tokenisasi	normalisasi
['keren', 'emang', 'bagus', 'worthit', 'dikelas', 'harga', 'nya', 'bagus', 'advan', 'mulai', 'laptopnya', 'semoga', 'makin', 'ditingkatkan', 'kualitasnya']	['keren', 'memang', 'bagus', 'worthit', 'dikelas', 'harga', 'ya', 'bagus', 'advan', 'mulai', 'laptopnya', 'semoga', 'makin', 'ditingkatkan', 'kualitasnya']
['performa', 'oke', 'bgt', 'bisa', 'dipakai', 'utk', 'kebutuhan', 'olga']	['performa', 'oke', 'banget', 'bisa', 'dipakai', 'untuk', 'kebutuhan', 'olga']
['barang', 'sampai', 'dengan', 'selamat', 'dan', 'pengiriman', 'cepat', 'terimakasih', 'advan']	['barang', 'sampai', 'dengan', 'selamat', 'dan', 'pengiriman', 'cepat', 'terimakasih', 'advan']

['performa', 'jamnya', 'keren', 'sampai', 'ditempat', 'dgn', 'selamat']	['performa', 'jamnya', 'keren', 'sampai', 'ditempat', 'dengan', 'selamat']
['keren', 'ni', 'sukses', 'terus', 'advan']	['keren', 'nih', 'sukses', 'terus', 'advan']

- 5) *Stopword Removal*: Penghapusan kata-kata umum yang tidak memiliki bobot informatif (misalnya, "yang", "di", "adalah") dari daftar *stopwords* yang telah dikurasi. Berikut merupakan contoh data hasil *stopword removal*:

TABEL VIII
Contoh data hasil *stopword removal*

normalisasi	stopword_removal
['keren', 'memang', 'bagus', 'worthit', 'dikelas', 'harga', 'ya', 'bagus', 'advan', 'mulai', 'laptopnya', 'semoga', 'makin', 'ditingkatkan', 'kualitasnya']	['keren', 'memang', 'bagus', 'worthit', 'dikelas', 'harga', 'bagus', 'advan', 'mulai', 'laptopnya', 'makin', 'ditingkatkan', 'kualitasnya']
['performa', 'oke', 'banget', 'bisa', 'dipakai', 'untuk', 'kebutuhan', 'olga']	['performa', 'oke', 'banget', 'bisa', 'dipakai', 'untuk', 'kebutuhan', 'olga']
['barang', 'sampai', 'dengan', 'selamat', 'dan', 'pengiriman', 'cepat', 'terimakasih', 'advan']	['sampai', 'selamat', 'pengiriman', 'cepat', 'terimakasih', 'advan']
['performa', 'jamnya', 'keren', 'sampai', 'ditempat', 'dengan', 'selamat']	['performa', 'jamnya', 'keren', 'sampai', 'ditempat', 'selamat']
['keren', 'nih', 'sukses', 'terus', 'advan']	['keren', 'nih', 'sukses', 'terus', 'advan']

- 6) *Stemming*: Menggunakan stemmer Sastrawi, setiap kata direduksi ke bentuk dasarnya (misalnya, "meningkatkan" menjadi "tingkat") untuk mengkonsolidasi fitur leksikal. Berikut merupakan contoh data hasil *stemming*:

TABEL IX
Contoh data hasil *Stemming*

Stopword Removal	Stemming
['keren', 'memang', 'bagus', 'worthit', 'dikelas', 'harga', 'bagus', 'advan', 'mulai', 'laptopnya', 'makin', 'ditingkatkan', 'kualitasnya']	['keren', 'memang', 'bagus', 'worthit', 'kelas', 'harga', 'bagus', 'advan', 'mulai', 'laptop', 'makin', 'tingkat', 'kualitas']
['performa', 'oke', 'banget', 'bisa', 'dipakai', 'untuk', 'kebutuhan', 'olga']	['performa', 'oke', 'banget', 'bisa', 'pakai', 'untuk', 'butuh', 'olga']
['sampai', 'selamat', 'pengiriman', 'cepat', 'terimakasih', 'advan']	['sampai', 'selamat', 'kirim', 'cepat', 'terimakasih', 'advan']
['performa', 'jamnya', 'keren', 'sampai', 'ditempat', 'selamat']	['performa', 'jam', 'keren', 'sampai', 'tempat', 'selamat']
['keren', 'nih', 'sukses', 'terus', 'advan']	['keren', 'nih', 'sukses', 'terus', 'advan']

- 7) *Negation Merging*: Melalui teknik penggabungan negasi, kata-kata penyangkal digabungkan secara sintaksis dengan kata yang mengikutinya menjadi satu token tunggal (misalnya, "tidak bagus" menjadi "tidakbagus"). Langkah ini bertujuan untuk mempertahankan konteks semantik sentimen yang sering kali hilang atau terdeteksi netral jika kata negasi dipisahkan dari kata sifatnya dalam model *Bag of Words*. Berikut merupakan contoh data hasil *negation merging*:

TABEL X
Contoh data hasil *negation merging*

Stemmed	Negation

['fungsi', 'baik', 'awet', 'dalam', 'pakai', 'video', 'unboxingnya', 'lama', 'jadi', 'tidak', 'bisa', 'diupload', 'min', 'terimakasih']	['fungsi', 'baik', 'awet', 'dalam', 'pakai', 'video', 'unboxingnya', 'lama', 'jadi', 'tidakbisa', 'diupload', 'min', 'terimakasih']
['jam', 'oke', 'banget', 'harga', 'tidak', 'smoe']	['jam', 'oke', 'banget', 'harga', 'tidaksmoe']
['produk', 'bagus', 'saja', 'awet', 'tapi', 'waktu', 'ngechas', 'chager', 'cepat', 'panas', 'baterai', 'tahan', 'hari', 'tidak', 'soal', 'cepat', 'habis', 'batre', 'tapi', 'kalau', 'produk', 'memang', 'bagus']	['produk', 'bagus', 'saja', 'awet', 'tapi', 'waktu', 'ngechas', 'chager', 'cepat', 'panas', 'baterai', 'tahan', 'hari', 'tidaksoal', 'cepat', 'habis', 'batre', 'tapi', 'kalau', 'produk', 'memang', 'bagus']
['tidak', 'ekspektasi', 'banyak', 'awal', 'suara', 'butut', 'set', 'pakai', 'equalizer', 'app', 'wow', 'jadi', 'bagus', 'seperti', 'earbuds', 'mahal', 'terus', 'cukup', 'kali', 'saja', 'set', 'konek', 'device', 'lain', 'tetap', 'bagus', 'kuali']	['tidakekspektasi', 'banyak', 'awal', 'suara', 'butut', 'set', 'pakai', 'equalizer', 'app', 'wow', 'jadi', 'bagus', 'seperti', 'earbuds', 'mahal', 'terus', 'cukup', 'kali', 'saja', 'set', 'konek', 'device', 'lain', 'tetap', 'bagus', 'kuali']

E. PENGELOMPOKAN DATA

Tahap ini merupakan inti dari proses klasifikasi, di mana data teks yang telah melalui tahap pra-pemrosesan dikonversi menjadi representasi numerik dan digunakan untuk membangun model prediktif.

- 1) Ekstraksi Fitur (Feature Extraction) Untuk mengubah data teks tidak terstruktur menjadi format yang dapat dipahami oleh algoritma pembelajaran mesin, kami menerapkan metode TF-IDF (Term Frequency-Inverse Document Frequency). Metode ini dipilih karena kemampuannya untuk memberikan bobot lebih tinggi pada kata-kata yang jarang muncul namun memiliki signifikansi kontekstual tinggi dalam membedakan

sentimen (seperti "kecewa", "puas", atau kata hasil penggabungan negasi seperti "tidakbagus"), sekaligus mengurangi bobot kata umum yang sering muncul namun minim makna.

- 2) Pelabelan Data (Data Labeling) Berbeda dengan pendekatan konvensional yang hanya mengandalkan rating bintang sebagai acuan sentimen, penelitian ini menerapkan metode Semi-Supervised Annotation (SSA). Proses pelabelan awal dilakukan dengan bantuan model AI Generatif (ChatGPT) untuk menentukan apakah sebuah ulasan bersentimen Positif, Negatif, atau Netral. Label yang dihasilkan oleh AI kemudian divalidasi melalui evaluasi manual oleh peneliti untuk memastikan akurasi dan konsistensi ground truth sebelum data digunakan.
- 3) Pembagian Data (Data Splitting) Setelah proses pelabelan selesai, dataset dibagi menggunakan skema hold-out validation. Data dipisahkan menjadi dua bagian dengan rasio 80:20, di mana 80% data dialokasikan sebagai data latih (training set) untuk pembelajaran model, dan 20% sisanya digunakan sebagai data uji (testing set) untuk mengevaluasi kinerja model pada data yang belum pernah dilihat sebelumnya.
- 4) Pelatihan Model (Model Training) Algoritma yang digunakan untuk klasifikasi sentimen dalam penelitian ini adalah Logistic Regression. Algoritma ini dipilih karena efisiensinya dalam menangani data teks berdimensi tinggi (hasil vektorisasi TF-IDF) dan kemampuannya memberikan probabilitas kelas yang jelas, yang sangat efektif untuk tugas klasifikasi biner maupun multikelas dalam analisis sentimen.

F. METRIK EVALUASI

Untuk memastikan model bisa bekerja dengan baik dan akurat kami menggunakan metrik evaluasi *accuracy* dan *f1-score (weighted)*. *accuracy* menggunakan rumus sebagai berikut.

$$Accuracy = \frac{Jumlah\ Prediksi\ Benar}{Total\ Jumlah\ Prediksi}$$

Lalu untuk *f1-score (weighted)* yaitu menggabungkan *precision* dan *recall* menjadi satu metrik untuk mengatasi masalah imbalance dataset karena dataset netral sangat sedikit. dengan rumus *precision* adalah,

$$Precision = \frac{TP}{TP + FP}$$

TP = True Positive yaitu prediksi positif yang benar
FP = False Positive yaitu prediksi positif yang salah.

lalu dengan rumus *recall* sebagai berikut,

$$Recall = \frac{TP}{TP + FN}$$

FN = False Negative yaitu data positif tapi diprediksi negatif.
Lalu untuk rumus F1-score nya sendiri ialah,

$$F1 = 2 \times \frac{Precision \times Recall}{Precision + Recall}$$

dan didapatkan hasil *Weighted F1* dengan rumus sebagai berikut

$$F1_{\text{weighted}} = \frac{\sum_{i=1}^k (F1_i \times n_i)}{\sum_{i=1}^k n_i}$$

IV. HASIL DAN DISKUSI

A. HASIL EKSPERIMEN DAN PENGUJIAN MODEL

Untuk membentuk model klasifikasi kami menggunakan metode *Semi Supervised Learning* dimana dataset yang kami gunakan berasal dari aplikasi Lazada yang kami berikan label positif, negatif atau netral oleh AI dengan model yaitu ChatGPT 4, setelah diberikan label kami mengevaluasi manual untuk *records* dengan *confidence* ≤ 0.8 apakah label yang diberikan sesuai dengan review *textnya*.

Setelah itu kami melakukan beberapa eksperimen dengan menguji beberapa komposisi jumlah antara data training dan juga data testing dengan beberapa model. Berikut adalah hasil percobaannya,

TABEL XI

Perbandingan Performa Beberapa Model dengan *Split Ratio* 70:30

Hasil Pengujian Model dengan Split Ratio 70:30				
Model	Accuracy	Precision	Recall	F1-Score
Logistic Regression	0.888000	0.900941	0.888000	0.893248
Naive Bayes	0.857000	0.734449	0.857000	0.791006
SVM	0.903000	0.898899	0.903000	0.897987
Random Forest	0.880000	0.864393	0.880000	0.858438

TABEL XII

Perbandingan Performa Beberapa Model dengan *Split Ratio* 80:20

Hasil Pengujian Model dengan Split Ratio 80:20				
Model	Accuracy	Precision	Recall	F1-Score
Logistic Regression	0.892054	0.904620	0.892054	0.897369
Naive Bayes	0.857571	0.735428	0.857571	0.791817
SVM	0.908546	0.901189	0.908546	0.903114

Random Forest	0.871064	0.848936	0.871064	0.851700
---------------	----------	----------	----------	----------

TABEL XIII

Perbandingan Performa Beberapa Model dengan *Split Ratio* 90:10


Hasil Pengujian Model dengan Split Ratio 90:10				
Model	Accuracy	Precision	Recall	F1-Score
Logistic Regression	0.898204	0.905560	0.898204	0.901403
Naive Bayes	0.856287	0.733228	0.856287	0.789994
SVM	0.901198	0.893097	0.901198	0.896256
Random Forest	0.871257	0.846178	0.871257	0.850349

Berdasarkan hasil pengujian performa model klasifikasi dengan tiga skenario pembagian data, yaitu split ratio 70:30, 80:20, dan 90:10, diperoleh bahwa setiap model menunjukkan tingkat kinerja yang berbeda. Evaluasi menggunakan metrik accuracy, precision, recall, dan F1-score menunjukkan bahwa Support Vector Machine (SVM) secara konsisten menghasilkan performa terbaik pada hampir seluruh skenario, khususnya pada split ratio 80:20 dengan nilai accuracy sebesar 0.908546 dan F1-score sebesar 0.903114. Hasil ini menunjukkan bahwa SVM memiliki kemampuan generalisasi yang baik serta keseimbangan yang optimal antara ketepatan dan kelengkapan klasifikasi.

Model Logistic Regression menunjukkan kinerja yang stabil dan kompetitif, terutama pada skenario dengan proporsi data latih yang lebih besar, sementara Random Forest memberikan hasil yang cukup baik namun belum mampu melampaui kinerja SVM. Di sisi lain, Naive Bayes menunjukkan performa paling rendah, khususnya pada metrik precision dan F1-score, yang mengindikasikan bahwa asumsi independensi fitur kurang sesuai dengan karakteristik data penelitian. Secara keseluruhan, Support Vector Machine dapat direkomendasikan sebagai model terbaik untuk digunakan dalam penelitian ini karena memberikan performa paling optimal dan konsisten pada berbagai variasi pembagian data.

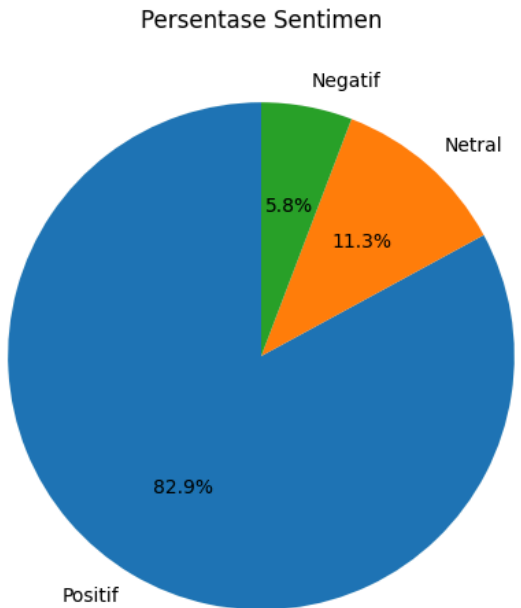
B. HASIL ANALISIS SENTIMEN TERHADAP BRAND

Setelah model dilatih, kami menggunakan model untuk mengklasifikasi sentimen brand Xiaomi. Dibawah ini adalah visualisasi WordCloud dari persebaran sentimen antara produk Advan dan juga Xiaomi.



Gambar 4. Pie Chart Distribusi Sentimen (Advan)

Berdasarkan pie chart persentase sentimen produk advan, mayoritas data termasuk dalam kategori sentimen positif dengan proporsi sebesar 85.7 persen. Selanjutnya, sentimen netral memiliki persentase sebesar 9.2 persen, sedangkan sentimen negatif merupakan kategori dengan jumlah paling kecil, yaitu sebesar 5.1 persen. Distribusi ini menunjukkan bahwa sebagian besar data yang dianalisis didominasi oleh sentimen positif, sementara sentimen netral dan negatif hanya mencakup sebagian kecil dari keseluruhan data.



Gambar 3. Pie Chart Distribusi Sentimen (Xiaomi)

Berdasarkan pie chart persentase sentimen, kategori sentimen positif memiliki proporsi terbesar dengan persentase sebesar 82.9 persen. Sentimen netral berada pada urutan


berikutnya dengan persentase sebesar 11.3 persen, sedangkan sentimen negatif memiliki proporsi paling kecil, yaitu sebesar 5.8 persen. Hasil ini menunjukkan bahwa sebagian besar data yang dianalisis termasuk dalam kategori sentimen positif, sementara sentimen netral dan negatif hanya mencakup sebagian kecil dari keseluruhan data.

Berdasarkan dua pie chart yang merepresentasikan distribusi sentimen terhadap produk Advan sebagai produk lokal dan Xiaomi sebagai produk asing, terlihat bahwa keduanya sama-sama didominasi oleh sentimen positif. Produk Advan menunjukkan persentase sentimen positif sebesar 85.7 persen, sentimen netral sebesar 9.2 persen, dan sentimen negatif sebesar 5.1 persen. Sementara itu, produk Xiaomi memiliki persentase sentimen positif sebesar 82.9 persen, sentimen netral sebesar 11.3 persen, dan sentimen negatif sebesar 5.8 persen.

Perbandingan kedua pie chart tersebut menunjukkan bahwa produk Advan memiliki proporsi sentimen positif yang lebih tinggi dibandingkan Xiaomi, sedangkan Xiaomi memiliki persentase sentimen netral dan negatif yang sedikit lebih besar. Meskipun terdapat perbedaan persentase pada masing-masing kategori sentimen, kedua produk tetap didominasi oleh sentimen positif, yang menunjukkan bahwa sebagian besar data ulasan terhadap produk lokal maupun produk asing berada pada kategori sentimen positif berdasarkan visualisasi yang ditampilkan.

Untuk melihat lebih detail komentar atau ulasan dari setiap produk sentimennya kamu melakukan visualisasi WordCloud untuk sentimen Positif, Negatif dan Netral pada produk Xiaomi dan Advan.

1) WordCloud Brand Advan



Gambar 5. WordCloud - Sentimen positif

Berdasarkan word cloud sentimen positif terhadap produk Advan, kemunculan kata-kata yang paling dominan seperti “bagus”, “mantap”, “kualitas”, “cepat”, dan “sesuai” dapat mengindikasikan bahwa ulasan positif cenderung banyak menyoroti aspek kualitas produk, kinerja, serta kesesuaian produk dengan deskripsi yang diberikan. Selain itu, keberadaan kata seperti “fungsi”, “performa”, “kirin cepat”, dan “terimakasih” dapat mencerminkan adanya penekanan pada pengalaman penggunaan produk dan proses pengiriman. Secara umum, pola kemunculan kata pada word cloud ini mengarah pada indikasi bahwa persepsi positif pengguna terhadap produk Advan berkaitan dengan kualitas, performa, dan pengalaman layanan yang terekam dalam ulasan.




Gambar 6. WordCloud - Sentimen negatif

Berdasarkan word cloud sentimen negatif terhadap produk Advan, kemunculan kata-kata yang dominan seperti "tidak", "bisa", "pakai", "rusak", dan "lambat" dapat mengindikasikan adanya ulasan yang menyoroti kendala dalam penggunaan produk. Selain itu, kata-kata seperti "kamera", "beli", "kirin", "kecewa", dan "belum" dapat mencerminkan adanya pengalaman pengguna yang kurang sesuai dengan harapan pada aspek fungsi produk maupun proses setelah pembelian. Secara umum, pola kemunculan kata pada word cloud ini mengarah pada indikasi adanya persepsi negatif yang berkaitan dengan kendala operasional, kualitas tertentu, serta pengalaman penggunaan yang kurang optimal sebagaimana terekam dalam ulasan pengguna.




Gambar 7. WordCloud - Sentimen netral

Berdasarkan word cloud sentimen netral terhadap produk Advan, kemunculan kata-kata yang dominan seperti "tapi", "bagus", "oke", dan "lumayan" dapat mengindikasikan adanya ulasan yang mengekspresikan penilaian yang bersifat seimbang antara aspek positif dan keterbatasan produk. Selain itu, kata-kata seperti "kualitas", "performa", "pakai", dan "kerja" dapat mencerminkan bahwa pengguna menyampaikan pengalaman penggunaan secara deskriptif tanpa kecenderungan penilaian yang kuat ke arah positif maupun negatif. Secara umum, pola kemunculan kata pada word cloud ini mengarah pada indikasi bahwa sentimen netral digunakan untuk menggambarkan kondisi produk sebagaimana adanya, dengan penekanan pada pengalaman penggunaan dan karakteristik produk yang diamati oleh pengguna.



Gambar 8. WordCloud - Sentimen positif

Word cloud sentiment positif Xiaomi ini mengindikasikan bahwa persepsi pengguna cenderung diasosiasikan dengan kata kata bernada apresiatif seperti "mantap", "bagus", "aman", "sesuai", dan "original" yang muncul dominan, sehingga secara asumptif dapat merefleksikan pengalaman pengguna yang dirasakan memuaskan terutama terkait kualitas produk dan kesesuaian dengan ekspektasi awal. Kemunculan kata seperti "fungsi", "fungsi baik", dan "awet" mengindikasikan adanya penilaian positif terhadap performa dan daya tahan produk, sementara kata "cepat", "packing rapi", dan "segel" dapat diasumsikan berkaitan dengan proses pengiriman dan kondisi barang yang diterima. Selain itu keberadaan kata "terima kasih" dan "seller" mengindikasikan potensi apresiasi terhadap layanan penjual, meskipun keseluruhan interpretasi ini masih bersifat indikatif dan merepresentasikan kecenderungan umum dari teks ulasan positif, tanpa kesimpulan final mengenai kualitas produk maupun layanan secara objektif.



Gambar 9. WordCloud - Sentimen negatif

Word cloud sentimen negatif Xiaomi ini mengindikasikan bahwa keluhan pengguna secara asumsi banyak diasosiasikan dengan kata kata seperti "bermasalah", "tidak bisa", "kecewa", dan "buruk" yang muncul dominan, sehingga dapat merefleksikan adanya pengalaman penggunaan yang dirasakan kurang memuaskan. Kemunculan kata seperti "pakai", "pakai lama", dan "baru" mengindikasikan potensi permasalahan yang dirasakan baik pada tahap awal maupun setelah penggunaan tertentu, sementara kata "admin", "chat", dan "respon" dapat diasumsikan berkaitan dengan interaksi layanan pelanggan yang dianggap kurang optimal. Selain itu kata "barang", "unit", "kabel", dan "wifi" mengindikasikan kemungkinan isu teknis atau komponen produk, sedangkan keberadaan kata "tidak ada", "harus", dan "lebih lama" secara asumsi mencerminkan hambatan dalam proses penyelesaian masalah, namun keseluruhan interpretasi ini tetap bersifat

indikatif dan belum dapat dipandang sebagai kesimpulan final mengenai kualitas produk maupun layanan Xiaomi secara menyeluruh.



Gambar 10. WordCloud - Sentimen netral

Word cloud sentimen netral Xiaomi ini mengindikasikan bahwa ulasan pengguna secara asumsi banyak berfokus pada deskripsi penggunaan dan penilaian fungsional yang bersifat informatif, yang tercermin dari dominasi kata seperti "ok", "ok tapi", "bagus", dan "sesuai". Kemunculan kata "cukup", "lumayan", dan "bisa" mengindikasikan adanya penilaian yang moderat dan tidak ekstrem, sementara kata "awet", "fungsi baik", dan "kualitas" dapat diasumsikan merepresentasikan evaluasi dasar terhadap performa produk tanpa ekspresi emosional yang kuat. Selain itu kata "harga", "produk", "packing", dan "sampai" mengindikasikan pembahasan aspek transaksi dan kondisi barang yang bersifat faktual, sehingga secara keseluruhan word cloud ini secara indikatif menggambarkan kecenderungan ulasan yang menekankan kesesuaian produk dengan deskripsi dan ekspektasi minimum, tanpa penilaian positif maupun negatif yang dominan.

C. HASIL ANALISIS SENTIMEN BERBASIS ASPEK TERHADAP BRAND

Untuk mengidentifikasi topik yang paling representatif dalam analisis sentimen berbasis aspek, penelitian ini melakukan pengujian hyperparameter tuning menggunakan metode Grid Search pada algoritma Latent Dirichlet Allocation (LDA) dengan representasi fitur TF-IDF dan CountVectorizer. Eksperimen dilakukan dengan memvariasikan parameter jumlah topik (3 hingga 6) serta nilai doc_topic_prior (α) dan topic_word_prior (η) pada rentang 0.1, 0.5, dan 0.9 untuk mengontrol kepadatan distribusi topik dalam dokumen dan kata dalam topik. Evaluasi kualitas model didasarkan pada perhitungan Coherence Score menggunakan metrik C_v untuk mengukur tingkat keterkaitan semantik antar kata dalam topik, serta Silhouette Score untuk menilai ketegasan pemisahan antar kluster topik, di mana konfigurasi parameter terbaik dipilih berdasarkan nilai Coherence Score tertinggi guna memastikan hasil analisis yang koheren dan mudah diinterpretasikan. Berikut ini adalah tabel pengujian dari hyperparameter tuning untuk sentimen negatif pada data ulasan advan.

TABEL XIV
Tabel Perbandingan Hasil Pengujian Hyperparameter Tuning CountVectorizer

Hasil Menggunakan CountVectorizer				
Num of	Alpha	Eta	Silhouette	Coherence

Topics			Score	Score
5	0.1	0.9	-0.058984	0.425038
6	0.9	0.9	-0.029194	0.416528
5	0.1	0.1	-0.059521	0.411522
4	0.9	0.9	0.000389	0.400857
3	0.9	0.9	0.006107	0.386328
6	0.9	0.5	-0.003086	0.385330
5	0.9	0.5	-0.006361	0.377740
5	0.9	0.9	-0.003821	0.373898
5	0.1	0.5	-0.059778	0.370083
6	0.5	0.9	-0.034781	0.363196
5	0.5	0.1	-0.025640	0.358514
3	0.5	0.9	-0.006098	0.357965
4	0.5	0.5	-0.010275	0.357593
6	0.1	0.5	-0.052427	0.356432
3	0.9	0.1	-0.006772	0.353000
3	0.1	0.9	-0.004092	0.352622
4	0.5	0.9	-0.003958	0.352532
4	0.9	0.5	-0.005323	0.350262
6	0.5	0.1	-0.050719	0.347656
6	0.5	0.5	-0.038507	0.347172
4	0.1	0.9	-0.016159	0.344492
6	0.1	0.1	-0.059484	0.343153
3	0.9	0.5	-0.000998	0.342559
6	0.1	0.9	-0.048452	0.339537
5	0.5	0.9	-0.045339	0.339253
3	0.1	0.5	-0.004092	0.339174
5	0.5	0.5	-0.037927	0.333788
3	0.5	0.1	-0.005674	0.332854
6	0.9	0.1	-0.010090	0.321110
4	0.1	0.5	-0.011975	0.320615
3	0.1	0.1	-0.005062	0.320014
4	0.9	0.1	-0.009260	0.319587
4	0.5	0.1	-0.013378	0.318283
3	0.5	0.5	-0.008159	0.314276
4	0.1	0.1	-0.010282	0.298529
5	0.9	0.1	-0.009052	0.298286

TABEL XV
Tabel Perbandingan Hasil Pengujian Hyperparameter Tuning TfIdfVectorizer

Hasil Menggunakan TfidfVectorizer				
Num of Topics	Alpha	Eta	Silhouette Score	Coherence Score
6	0.1	0.1	-0.001493	0.410765
3	0.1	0.1	0.003127	0.401749
6	0.1	0.9	0.000369	0.401291
3	0.5	0.9	0.010907	0.401012
6	0.1	0.5	-0.001412	0.391952
4	0.5	0.5	0.009098	0.391521
5	0.1	0.1	-0.001739	0.385179
5	0.1	0.9	-0.000668	0.385101
5	0.5	0.1	0.006653	0.382747
3	0.1	0.5	0.001989	0.381241
3	0.1	0.9	0.002198	0.381241
5	0.1	0.5	-0.001815	0.379251
6	0.5	0.9	0.012967	0.371157
5	0.5	0.9	0.012472	0.369495
3	0.5	0.5	0.008710	0.365740
6	0.5	0.1	0.005742	0.362203
6	0.5	0.5	0.012992	0.357357
3	0.9	0.5	0.009294	0.357281
4	0.5	0.9	0.012229	0.354204
6	0.9	0.1	0.001797	0.342717
5	0.5	0.5	0.011118	0.341541
5	0.9	0.1	0.004516	0.340781
3	0.9	0.1	0.006937	0.338104
6	0.9	0.5	0.013072	0.335274
3	0.5	0.1	0.007391	0.334584
4	0.9	0.1	0.005125	0.324887
5	0.9	0.5	0.012017	0.324074
5	0.9	0.9	0.010480	0.323536
6	0.9	0.9	0.009241	0.321787
4	0.1	0.9	0.001873	0.314010
4	0.1	0.5	0.000877	0.312773
4	0.5	0.1	0.007633	0.312634

4	0.1	0.1	0.001986	0.312354
4	0.9	0.9	0.006813	0.294990
4	0.9	0.5	0.008732	0.294324
3	0.9	0.9	0.009381	0.2

Berdasarkan hasil komparasi kinerja hyperparameter tuning, representasi fitur menggunakan CountVectorizer menunjukkan keunggulan dalam aspek koherensi semantik dibandingkan TfidfVectorizer. Nilai Coherence Score tertinggi sebesar 0.425038 diperoleh melalui model CountVectorizer dengan konfigurasi 5 topik dan parameter prioritas $\alpha = 0.1$ serta $\eta = 0.9$, mengungguli pencapaian terbaik model TfidfVectorizer yang hanya mencapai skor koherensi 0.410765 pada konfigurasi 6 topik ($\alpha = 0.1$, $\eta = 0.1$). Meskipun model TfidfVectorizer secara konsisten menghasilkan Silhouette Score positif yang mengindikasikan pemisahan antar kluster yang lebih tegas secara matematis, penelitian ini memprioritaskan penggunaan model terbaik dari CountVectorizer karena dalam pemodelan topik, skor koherensi yang tinggi lebih krusial untuk menjamin interpretabilitas dan kebermaknaan topik yang dihasilkan, kendati memiliki nilai Silhouette Score yang negatif.

Selanjutnya, konfigurasi model terbaik tersebut ($k=5$, $\alpha = 0.1$, $\eta = 0.9$) diterapkan untuk mengekstraksi struktur topik laten dari korpus ulasan negatif. Proses ini menghasilkan lima kluster topik yang merepresentasikan permasalahan utama atau aspek keluhan pengguna terhadap produk Advan. Identifikasi topik dilakukan dengan menganalisis sepuluh kata kunci (top words) yang memiliki bobot probabilitas tertinggi dalam setiap distribusi topik, di mana kumpulan kata tersebut merefleksikan konteks semantik yang mendasari keluhan konsumen. Distribusi kata kunci dominan yang membentuk kelima topik tersebut disajikan secara rinci dalam Tabel berikut.

TABEL XVI
Tabel Hasil Topic Modeling dengan LDA

Topik	Kata Kunci Utama
Topik 1	bisa, sampai, tidakada, mati, belum, pakai, saya, kalau, beli, ada
Topik 2	tapi, jam, layar, suara, pakai, baru, ada, padahal, banget, kecil
Topik 3	pakai, tidakbisa, tapi, bagus, sih, datang, rusak, beli, belum, cuma
Topik 4	tidakbisa, tapi, cuma, hp, datang, retur, sama, laptop, layar, saja
Topik 5	bagus, kali, kualitas, jernih, kerja, banget, performa, lensa, tapi, kecewa

Untuk menerjemahkan kluster kata yang dihasilkan oleh LDA menjadi wawasan yang dapat ditindaklanjuti, dilakukan proses interpretasi dan pelabelan topik secara manual dengan menganalisis konteks semantik dari kata kunci dominan. Penentuan label aspek ini didasarkan pada asosiasi antar kata yang paling kuat merepresentasikan jenis keluhan

spesifik yang dialami pengguna, mulai dari kendala perangkat keras hingga layanan purna jual. Hasil identifikasi dan penamaan aspek untuk kelima topik negatif yang ditemukan dirangkum dalam Tabel berikut.

Topik	Label Topik (Nama Aspek)	Kata Kunci
1	Produk Mati Total (Dead on Arrival)	mati, belum, sampai, tidak ada
2	Kualitas Multimedia & Fisik	layar, suara, jam, kecil
3	Kerusakan Barang saat Diterima	rusak, datang, beli, tidak bisa
4	Layanan Retur & Purna Jual	retur, hp, laptop, tidak bisa
5	Kualitas Kamera & Performa	lensa, jernih, performa, kualitas, kecewa

V. KESIMPULAN

Penelitian ini berhasil membuktikan bahwa produk teknologi lokal (Advan) memiliki daya saing persepsi yang kompetitif di pasar Indonesia, ditunjukkan dengan dominasi sentimen positif sebesar 85,7% yang justru sedikit mengungguli produk asing (Xiaomi) di angka 82,9%. Temuan ini membantah stigma inferioritas produk lokal, di mana preferensi konsumen terhadap Advan sangat didorong oleh kepuasan atas kesesuaian spesifikasi dengan harga (value for money) dan kinerja fungsional. Sebaliknya, persepsi positif terhadap Xiaomi lebih banyak diasosiasikan dengan reputasi merek jangka panjang seperti keawetan dan orisinalitas produk, yang menunjukkan bahwa produk lokal telah diterima dengan baik secara fungsional namun masih perlu membangun kepercayaan terhadap durabilitas merek.

Meskipun demikian, analisis mendalam menggunakan Latent Dirichlet Allocation (LDA) pada sentimen negatif menyingkap bahwa hambatan utama bagi produk lokal untuk mendominasi pasar bukanlah kurangnya inovasi fitur, melainkan inkonsistensi pada kontrol kualitas dan layanan purna jual. Lima aspek krusial yang menjadi sumber keluhan utama pengguna Advan meliputi kegagalan fungsi saat barang diterima (Dead on Arrival), kerusakan fisik, defek pada komponen multimedia, serta kerumitan proses retur garansi. Oleh karena itu, strategi kunci untuk mendukung kemandirian ekonomi digital nasional harus berfokus pada pembenahan manajemen rantai pasok dan pengetatan Quality Control guna menekan tingkat produk cacat, serta reformasi layanan purna jual untuk meningkatkan loyalitas konsumen setara dengan standar global. Mendominasi dan menjadi preferensi utama masyarakat Indonesia dalam mencari layanan sesuai kebutuhan. Harapannya dengan hasil riset kami aplikasi layanan lokal bisa lebih diminati dan Indonesia bisa menjadi negara dengan kemandirian digital yang akan berpengaruh ke Indonesia sebagai negara yang memiliki kemandirian ekonomi.

REFERENSI

- [1] Ramdan, D. S., Apnena, R. D., & Sugianto, C. A. (2023). Film Review Sentiment Analysis: Comparison of Logistic

Regression and Support Vector Classification Performance Based on TF-IDF. *Journal of Applied Intelligent System*, 8(3).

- [2] Bahtiar, S. A. H., Dewa, C. K., & Luthfi, A. (2023). Comparison of Naïve Bayes and Logistic Regression in Sentiment Analysis on Marketplace Reviews Using Rating-Based Labeling. *Journal of Information Systems and Informatics*, 5(3).
- [3] Liu, B. (2012). Sentiment Analysis and Opinion Mining. *Synthesis Lectures on Human Language Technologies*, 5(1).
- [4] Martin, W., Sarro, F., Jia, Y., Zhang, Y., & Harman, M. (2017). A Survey of App Store Analysis for Software Engineering. *IEEE Transactions on Software Engineering*, 43(9).
- [5] Halevy, A., Norvig, P., & Pereira, F. (2009). The Unreasonable Effectiveness of Data. *IEEE Intelligent Systems*, 24(2).
- [6] Zimmer, M. (2010). "But the data is already public": on the ethics of research in Facebook. *Ethics and Information Technology*, 12(4).
- [7] Adriani, M., Asian, J., Nazief, B., Tahaghoghi, S. M., & Williams, H. (2007). Stemming Indonesian: A Confix-Stripping Approach. *ACM Transactions on Asian Language Information Processing*, 6(4).
- [8] Powers, D. M. W. (2011). Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness & Correlation. *Journal of Machine Learning Technologies*, 2(1).
- [9] Dani, A. H., Puspaningrum, E. Y., Mumpuni, R. (2024). Studi Performa TF-IDF dan Word2Vec Pada Analisis Sentimen Cyberbullying, 2(2).
- [10] Khomsah, S., Aribowo, A. S. (2022). Model Semi-supervised Learning Menggunakan Logistic Regression Untuk Anotasi Sentimen, 1(4).
- [11] Angelina, S. J., Negara, A. B. P., Muhandi, H. (2023). Analisis Pengaruh Penerapan Stopword Removal Pada Performa Klasifikasi Sentimen Tweet Bahasa Indonesia, 1(2).
- [12] Badan Pusat Statistik, "Statistik Telekomunikasi Indonesia 2024," *Bps.go.id*, 11 Jul. 2025. [Daring]. Tersedia: <https://www.bps.go.id/id/publication/2025/08/29/beaa2be400eda6ce6c636ef8/statistik-telekomunikasi-indonesia-2024.html>.
- [13] N. W. Utami, "Alasan Konsumen Memilih Produk Luar Negeri," *Jurnal.id*, [Tanpa Tanggal]. [Daring]. Tersedia: <https://www.jurnal.id/id/blog/alasan-konsumen-memilih-produk-luar-negeri/>.
- [14] M. R. Affandi, B. L. P. Dasuha, dan D. S. Parapat, "Dinamika Digitalisasi Dan Manajemen Keuangan UMKM: Literature Review Implementasi Fintech dan Digital Marketing Pada UMKM," *Jurnal Manajemen Dan Pemasaran (JUMPER)*, vol. 3, no. 2, 2025.
- [15] Kementerian Keuangan Republik Indonesia, "Targetkan Pertumbuhan Ekonomi 5,4% di 2026," *Kemenkeu.go.id*, 22 Agt. 2025. [Daring]. Tersedia: <https://www.kemenkeu.go.id/informasi-publik/publikasi/b>

[erita-utama/Targetkan-Pertumbuhan-Ekonomi-5.4-di-2026](#).

- [16] F. A. Firdausi, Indriati, dan A. Ridok, "Analisis Sentimen Pengguna Jalan Tol Tangerang - Merak dengan Metode Naïve Bayes dan Seleksi Fitur Query Expansion Ranking," *Jurnal Pengembangan Teknologi Informasi dan Ilmu Komputer*, vol. 1, no. 1, 2017.
- [17] S. Mutmainah, "Analisis Sentimen dan Pemodelan Topik pada Feedback Pengguna Aplikasi Telemedicine Platform Android," Tesis Magister, Universitas Islam Indonesia, Yogyakarta, 2023.
- [18] O. Babalola, B. Ojokoh, dan O. Boyinbode, "Comprehensive Evaluation of LDA, NMF, and BERTopic's Performance on News Headline Topic Modeling," *Journal of Computing Theories and Applications*, vol. 2, no. 2, hal. 268-289, Nov. 2024.
- [19] C. Y. Sy, L. L. Maceda, N. M. Flores, dan M. B. Abisado, "Unsupervised Machine Learning Approaches in NLP: A Comparative Study of Topic Modeling with BERTopic and LDA," *International Journal of Intelligent Systems and Applications in Engineering*, vol. 12, no. 21s, hal. 3276-3283, 2024.
- [20] Samsir, Ambiyar, U. Verawardina, F. Edi, dan R. Watrianthos, "Analisis Sentimen Pembelajaran Daring Pada Twitter di Masa Pandemi COVID-19 Menggunakan Metode Naïve Bayes," *Jurnal Media Informatika Budidarma*, vol. 5, no. 1, p. 149, 2021, doi: 10.30865/mib.v5i1.2604.
- [21] A. F. Anees, A. Shaikh, A. Shaikh, dan S. Shaikh, "Survey Paper on Sentiment Analysis: Techniques and Challenges," *EasyChair*, pp. 2516–2314, 2020. [Online]. Available: https://login.easychair.org/publications/preprint_download/Sc2h
- [22] S. W. Kim dan J. M. Gil, "Research paper classification systems based on TF-IDF and LDA schemes," *Human-Centric Computing and Information Sciences*, vol. 9, no. 1, 2019, doi: 10.1186/s13673-019-0192-7.